

第3回 Math-iine learning Learning Functions: When Is Deep Better Than Shallow

1/28

Contents

1	Introduction	1
2	Previous Work	1
3	Compositional functions	1
4	Main results	1
4.1	Deep and shallow neural networks	2

1 Introduction

この論文では,one-hidden layer のニューラルネットワークと deep network を比較する.

2 Previous Work

3 Compositional functions

4 Main results

この章では, shallow network,deep network の2つの場合に近似定理を述べる. 2つとは, ReLU による deep network と deep Gaussian network である. *degree of approximation* は以下で定義される.

$$\text{dist}(f, V_n) = \inf_{P \in V_n} \|f - P\| \quad (1)$$

4.1 Deep and shallow neural networks

$I^d := [-1, 1]^d, \mathbb{X} = C(I^d, \mathbb{R})$ とし, $\|f\| = \max_{x \in I^d} |f(x)|$ とする. S_n を n 個の *unit* を持つ *shallow network* のなす集合とする. すなわち,

$$S_n := \{f : \mathbb{R}^d, \mathbb{R} \text{ がある } w_k^i n \mathbb{R}^d, b_k, a_k \in \mathbb{R} \text{ が存在し, } f(x) = \sum_{k=1}^n a_k \sigma(w_k x + b_k)\}$$

この時, 訓練パラメータが $(d+2)n$ 個存在する.(メタ的で数学的ではない). $W_{r,d}^{NN}$ で r 回連続偏微分可能であって, $\|f\| + \sum_{1 \leq |k|_1 \leq r} \|D^k f\| \leq 1$ を満たすもの全体とする. また, $W_{H,r,2}^{NN}$ を以下で定義する.

$$W_{H,r,2}^{NN} := \{h | h = f_{11} \circ \dots \circ f_{k2^k}(f_{ij} \in W_{r,2}^{NN})\}$$

\mathcal{D}_n を S_n に属する関数の合成で書けるもの全体とする. 上の書き方, かなりまずいけど, $f_1(f_2(1, f_2(2)))$ で表せるもの? つまり, d が実質 2 のものということですかね. この時はパラメータの個数が $d = 2^m$ とした時に, $(d+2)m(1+2+\dots+2^{m-1}) = (d+2)m(d-1)$ となる.

Theorem 4.1. $\sigma : \mathbb{R} \rightarrow \mathbb{R}$ を無限回微分可能であって, \mathbb{R} の任意の開区間上で, 多項式でないとする. この時以下が成り立つ.

1. 任意の $f \in W_{r,d}^{NN}$ に対し,

$$\text{dist}(f, S_n) = O(n^{-r/d}) \quad (2)$$

2. 任意の $f \in W_{H,r,d}^{NN}$ に対し,

$$\text{dist}(f, \mathcal{D}_n) = O(n^{-r/2}) \quad (3)$$

Proof. 1 つめの主張は他の論文にて示した. 2 つめの主張を示す. f が無限回微分可能な時, 特によりブシツツ連続である. よって, $f(g_1, g_2) - f(P_1, P_2) \leq M|g_1 - P_1||g_2 - P_2|$ となる. これより,

$$\begin{aligned} |f(g_1, g_2) - P_0(P_1, P_2)| &\leq |f(g_1, g_2) - f(P_1, P_2)| + |f(P_1, P_2) - P_0(P_1, P_2)| \\ &\leq M|g_1 - P_1||g_2 - P_2| + \text{dist}(f, S_n) \end{aligned}$$

となる. $|g_1 - P_1||g_2 - P_2| \leq O(n^{-r})$ となるので. $f(g_1, g_2) - P_0(P_1, P_2) = O(n^{-r/2})$ となる. これを inductive に続けていけばよい. \square

Remark. オーダとしてはこれが限界であることが示されている.